CENTRO UNIVERSITÁRIO FEI

LUCAS MATEUS DE MORAES - RA: 22.220.004-0

ORIENTADOR: PROF. DR. CHARLES HENRIQUE PORTO FERREIRA

APLICAÇÃO DE TÉCNICAS DE PROCESSAMENTO DE LINGUAGEM NATURAL PARA AVALIAÇÃO AUTOMÁTICA DE QUESTÕES DISSERTATIVAS

São Bernardo do Campo

2023

RESUMO

Resumo em português, resumir introdução, insights da revisão, metodologia e proposta experimental.

O presente trabalho tem como objetivo analisar a similaridade semântica entre a resposta padrão de uma questões e a resposta dissertativa de um alunos, tentando avaliar um grau de parafraseamento, ou uma forma de representação de texto, que indique um possível resultado de correção para aquela respostas.

A proposta possui seus desafios de pesquisa, estudo e desenvolvimento, porém, não possui problemas significativos em relação a obter bases de dados ou lidar com dados sensíveis. Além de que, possui uma valor de contribuição valioso para a presente instituição de ensino e outras universidades, também sendo capaz de contribuir com o ensino de forma geral, pois, o uso de inteligência artificial (*AI*) e processamento de linguagem natural (*NLP*) aplicados a educação ainda é um tópico pouco explorado e de grande relevância, podendo assim, tornar a universidade e o presente trabalho uma possível referência no assunto, caso seu desenvolvimento futuro seja bem sucedido.

Palavras-chave: Semantic Similarity; Paraphrase Detection; Natural Language Processing; Evaluation of Descriptive Answers

ABSTRACT

The present work aims to analyze the semantic similarity between the standard response to a question and a student's essay-type response, attempting to assess a degree of paraphrasing or a form of text representation that indicates a potential grading outcome for that response.

The proposal presents challenges in terms of research, study, and development; however, it does not encounter significant issues regarding obtaining databases or handling sensitive data. Moreover, it holds valuable contribution potential for the current educational institution and other universities. It is also capable of contributing to education in general, as the use of artificial intelligence (*AI*) and natural language processing (*NLP*) applied to education is still a relatively unexplored and highly relevant topic. Therefore, the university and the present work could potentially become a reference in the field if its future development proves successful.

Keywords: Semantic Similarity; Paraphrase Detection; Natural Language Processing; Evaluation of Descriptive Answers

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de legenda. 10

Figura 2 – Figura da tabela de revisão bibliográfica sumarizada. 14

LISTA DE TABELAS

Tabela 1 – Tabela do funil de leitura. 14

SUMÁRIO

1 INTRODUÇÃO 7
1.1 OBJETIVO 8
1.2 QUESTÕES DE PESQUISA 8
2 CONCEITOS 10
2.1 PROCESSAMENTO DE LINGUAGEM NATURAL 10
2.2 REPRESENTAÇÃO DE TEXTOS 10
2.2.1 TFIDF 11
2.2.2 Word embedding 11
2.3 SIMILARIDADE DE TEXTOS 11
2.3.1 Palavras chaves 11
2.3.2 Frequência de palavras 11
2.3.3 Distância de Jaccard 11
2.3.4 Distância de Cosseno 12
2.3.5 Distância Euclidiana 12
2.3.6 Language Models 12
2.3.6.1 Parafraseamento 12
2.4 MÉTRICAS DE AVALIAÇÃO 12
2.4.1 Acurácia 12
3 REVISÃO BIBLIOGRÁFICA 13
4 METODOLOGIA 16
4.1 ABORDAGEM DE PESQUISA: 16
4.2 BASES DE DADOS: 16
4.3 MATERIAIS: 16
4.4 MÉTODOS: 17
4.5 AVALIAÇÃO: 18
5 PROPOSTA EXPERIMENTAL 19
6 CONCLUSÃO 21
REFERÊNCIAS 22

1 INTRODUÇÃO

Até 2 páginas, incluindo seção de objetivo abaixo. Contextualizar problema e possível solução. Sugere-se relacionar com outras pesquisas ou *cases* de mercado. Pode-se citar noticias de jornais, postagens de blogs confiáveis como medium, towards data science, technoblog, etc...(4G2009)

Na atualidade das instituições de ensino, uma variedade de métodos de avaliação são empregados para mensurar o aprendizado dos alunos, destacando-se entre eles as questões dissertativas, nas quais os alunos devem fornecer suas respostas de maneira textual. Esse método proporciona ao professor uma compreensão mais aprofundada da linha de raciocínio do aluno durante a correção, possibilitando assim, uma avaliação mais precisa do nível de aprendizado alcançado e um melhor acompanhamento da evolução do aluno ao longo do tempo (OLIVEIRA; SANTOS, 2005).

Embora a precisão da avaliação seja uma vantagem desse método, o mesmo exige maior tempo de leitura, análise e compreensão de cada questão por parte do professor, uma vez que ele precisará analisar integralmente o conteúdo dos textos fornecidos como resposta pelos alunos. Tal dificuldade pode levar o docente a preferir questões objetivas, que, por possuírem um gabarito, demandam um tempo menor de correção. Entretanto, é importante ressaltar que as questões objetivas não atingem o mesmo nível de precisão na avaliação em comparação com as questões dissertativas, uma vez que possibilitam que o aluno escolha uma alternativa de maneira aleatória e possa obter a resposta correta mesmo sem ter nenhum conhecimento da mesma, ao contrário das questões dissertativas, em que essa possibilidade não existe.

A utilização de avaliações dissertativas é utilizado em apenas 30% das formas de avaliação aplicadas aos alunos, conforme demonstrado em um estudo realizado por (OLIVEIRA; SANTOS, 2005). Este estudo aborda as vantagens das avaliações dissertativas e sua maior adequação para a avaliação do desempenho e acompanhamento do progresso dos alunos no processo de aprendizado. Considerando esse contexto, seria benéfico para as instituições de ensino adotar mais frequentemente avaliações dissertativas. No entanto, como mencionado anteriormente, um dos principais impeditivos da adoção desse método seria o aumento na carga de trabalho dos professores responsáveis pelas correções. Dessa forma, o presente trabalho tem por objetivo propor uma abordagem para realizar avaliação automática das respostas dissertativas dos alunos, comparando-as com uma resposta padrão fornecida por um especialista da área como modelo do conhecimento esperado para aquela questão.

De forma geral, a abordagem proposta irá avaliar o "grau de similaridade" entre as respostas das questões levando em consideração propriedades estatística e semântica dos textos. Sendo assim, pretende-se propor uma métrica que possa mensurar a similaridade entre as respostas. Para que essa avaliação seja efetivamente realizada, uma série de fatores, os quais podemos considerar como elementos relevantes na composição de uma resposta, devem ser considerados. Entre esses fatores pode-se citar: presença de palavas chaves, número de modificações para transformar uma resposta na outra, ordem das palavras, similaridade de texto, grau de parafraseamento, entre outros.

1.1 OBJETIVO

O objetivo final deste trabalho é o desenvolvimento e implementação de uma abordagem automatizada de avaliação para respostas dissertativas em ambientes educacionais. A proposta busca simplificar o processo de correção manual dessas respostas, promovendo uma análise precisa do desempenho dos alunos e reduzindo a carga de trabalho sobre os professores. As metas planejadas podem ser especificadas nos seguintes tópicos:

a) Desenvolver um algoritmo robusto para calcular para mensurar a similaridade semântica entre respostas dissertativas e uma resposta padrão.
b) Considerar fatores como a presença de palavras-chave, quantidade de repetições de palavras, grau de parafraseamento, distância entre cossenos dos textos e ordem das palavras na avaliação automática.
c) Validar a eficácia da técnica por meio de estudos de caso e comparações com dados de avaliações já corrigidas.
d) Como última meta, caso as anteriores sejam alcançadas com sucesso, planejar a integração da técnica com plataformas educacionais existentes ou com um protótipo, testando seu funcionamento na prática, o que pode torná-la acessível e aplicável em ambientes reais no futuro.

1.2 QUESTÕES DE PESQUISA

O tema abordado levanta importantes questões de pesquisa, nas quais o presente trabalho buscará responder os seguintes questionamentos:

a) Toda resposta correta pode ser considerada, em algum grau, uma paráfrase de uma resposta padrão?

Título	Fonte	Referência
Determining Degree of Relevance of Reviews Using a Graph-Based Text Representation	IEEE	(RAMACHANDRAN; GEHRINGER, 2011)
A Chinese text paraphrase detection method based on dependency tree	IEEE	(JIANG; HAO; ZHU, 2016)
Nowhere to Hide: Finding Plagiarized Documents Based on Sentence Similarity	IEEE	(GUSTAFSON; PERA; NG, 2008)
Enhanced Text Matching Based on Semantic Transformation	IEEE	(ZHANG et al., 2020)
Semantic similarity based assessment of descriptive type answers	IEEE	(MEENA; LAWRANCE, 2016)
A comparative analysis of various approaches for automated assessment of descriptive answers	IEEE	(KAUR; SASIKUMAR, 2017)
A reliable approach to automatic assessment of short answer free responses	SSL	(BACHMAN, Lyle F. et al., 2002b)
A Descriptive Answer Evaluation System Using Cosine Similarity Technique	IEEE	(THALOR, 2021)
An Intelligent System for Evaluation of Descriptive Answers	IEEE	(BAGARIA et al., 2020)
Application Research of Similarity Algorithm in the Design of English Intelligent Question Answering System	IEEE	(ZHANG, 2022)
Near duplicate text detection using graph depiction	IEEE	(POULOS, 2016)
Recognition of Parallelism Sentence Based on Recurrent Neural Network	IEEE	(DAI et al., 2018)
LSGC: An Interactive Text Matching Model Combined with Enhanced Encoding	IEEE	(WANG et al., 2022)
A software system for determining the semantic similarity of short texts in Serbian	IEEE	(BATANOVIĆ; FURLAN; NIKOLIĆ, 2011)
Arabic Semantic Textual Similarity Identification based on Convolutional Gated Recurrent Units	IEEE	(MAHMOUD; ZRIGUI, 2021)
A Chinese text paraphrase detection method based on dependency tree	IEEE	(JIANG; HAO; ZHU, 2016)
Using paraphrases to improve tweet classification: Comparing WordNet and word embedding approaches	IEEE	(LI et al., 2016)
SemEval-2020 Task 1: Unsupervised Lexical Semantic Change Detection	SSL	(SCHLECHTWEG et al., 2020)
SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Evaluation	SSL	(CER et al., 2017)
Use of Syntactic Similarity Based Similarity Matrix for Evaluating Descriptive Answer	IEEE	(PAUL; PAWAR, 2014)
Chapter 16 - Semantic similarity–based descriptive answer evaluation	SCD	(SHAUKAT et al., 2021)
A Study of Automated Evaluation of Student's Examination Paper using Machine Learning Techniques	IEEE	(SANUVALA; FATIMA, 2021)
Online Examination with short text matching	IEEE	(KUDI et al., 2014)
Towards Automated Evaluation of Handwritten Assessments	IEEE	(ROWTULA; OOTA; C.V, 2019)
Automatic Short Answer Grading (ASAG) using Attention-Based Deep Learning MODEL	IEEE	(AMUR; HOOI; SOOMRO, 2022)
Semantic similarity–based descriptive answer evaluation	SSL	(SHAUKAT et al., 2021)

b) A partir de qual ponto pode-se dizer que o grau de paráfrase entre os textos da resposta de um aluno e a resposta padrão indica corretude? Ou, em vez de uma saída binária, o resultado deve ser representado por uma escala variável?

c) Quais parâmetros podem ser considerados como componentes relevantes para pontuar a similaridade semântica entre as respostas?

d) Esses parâmetros podem definir uma pontuação que funcione de maneira geral quando aplicada a casos reais e práticos de correções dissertativas?

2 CONCEITOS

Até 3 páginas. Sugestões: 1) separar conceitos principais em seções; 2) As citações devem ser preferencialmente de livros ou artigos, evitar blogs, sites de noticias, sites tipo medium etc...; 3)Fazer um parágrafo introdutório retomando o objetivo e citando quais conceitos irão abordar nesse capitulo. 4) Considerar por exemplo métodos que serão implementados, métodos de avaliação, etc.. . Abaixo um exemplo de figura. Sempre citar no texto Figura 1

Para o bom desenvolvimento do projeto é necessário a revisão de assuntos basilares para *NLP* e um aprofundamento nos principais tópicos relacionados as técnicas utilizadas na área. Assim livros como *Introduction to natural language processing* (BACHMAN, Lyle F et al., 2002a) e *Machine Learning: An Algorithmic Perspective* (MARSLAND, 2014), serão importantes para o aprendizado desses tópicos.

2.1 PROCESSAMENTO DE LINGUAGEM NATURAL

O Processamento de Linguagem Natural (PLN) refere-se à aplicação de técnicas computacionais para a interpretação e manipulação de linguagem humana. Envolve o desenvolvimento de algoritmos e modelos que capacitam computadores a compreender, analisar e gerar texto de maneira semelhante ao entendimento humano.

2.2 REPRESENTAÇÃO DE TEXTOS

A Representação de Textos é crucial para permitir que algoritmos compreendam palavras e documentos. Duas técnicas comuns são TFIDF (Term Frequency-Inverse Document Frequency) e Word Embedding. O TFIDF avalia a importância de uma palavra em um documento, enquanto o Word Embedding mapeia palavras em vetores contínuos, capturando relações semânticas.

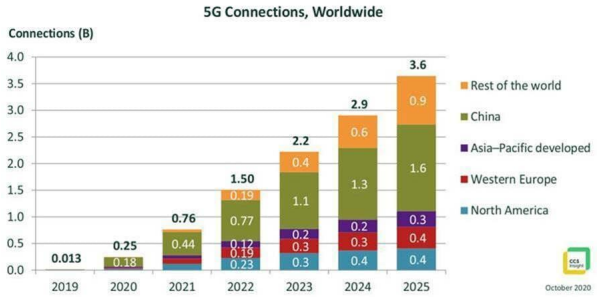

Figura 1 – Exemplo de legenda.

2.2.1 TFIDF

O TFIDF é uma técnica que atribui pesos a palavras com base em sua frequência no documento e em todo o conjunto de documentos. Palavras frequentes em um documento, mas raras no conjunto de documentos, recebem pontuações mais altas, destacando sua relevância no contexto do documento específico.

2.2.2 Word embedding

O Word Embedding é uma técnica que mapeia palavras em vetores de números reais, capturando relações semânticas e contextuais. Essa representação densa permite que algoritmos de PLN compreendam a similaridade e a semântica entre palavras.

2.3 SIMILARIDADE DE TEXTOS

A Similaridade de Textos é fundamental para comparar documentos ou palavras. Diversas métricas são empregadas, como Palavras-Chave, Frequência de Palavras, Distância de Jaccard, Distância de Cosseno, Distância Euclidiana e Modelos de Linguagem.

2.3.1 Palavras chaves

A similaridade pode ser avaliada considerando as palavras-chave mais relevantes em documentos. A sobreposição ou relevância compartilhada entre essas palavras indica o grau de similaridade.

2.3.2 Frequência de palavras

Medir a similaridade com base na frequência de palavras é uma abordagem simples. Documentos com termos semelhantes ou proporções de termos comuns mais altas são considerados mais similares.

2.3.3 Distância de Jaccard

A Distância de Jaccard avalia a similaridade entre conjuntos, medindo a proporção de elementos comuns entre dois conjuntos. Para texto, representa a sobreposição de palavras entre dois documentos.

2.3.4 Distância de Cosseno

A Distância de Cosseno mede o ângulo entre dois vetores de palavras, representando a similaridade direcional entre documentos. Quanto menor o ângulo, maior a similaridade.

2.3.5 Distância Euclidiana

A Distância Euclidiana calcula a distância geométrica entre pontos em um espaço vetorial. Em texto, representa a dissimilaridade entre as distribuições de palavras.

2.3.6 Language Models

Os Modelos de Linguagem, como os de Parafraseamento, buscam entender a similaridade semântica entre frases ou documentos, indo além da análise baseada em palavras.

2.3.6.1 Parafraseamento

Modelos de Parafraseamento são específicos para avaliar a similaridade entre frases ou documentos que expressam a mesma ideia de maneira diferente. Esses modelos buscam capturar nuances semânticas e estruturais, identificando relações de equivalência entre diferentes formulações.

2.4 MÉTRICAS DE AVALIAÇÃO

As Métricas de Avaliação quantificam o desempenho de modelos de PLN. A Acurácia é uma medida fundamental, representando a proporção de predições corretas em relação ao total. Outras métricas, como Precisão, Revocação e F1-Score, oferecem insights adicionais sobre o desempenho do modelo em diferentes aspectos da classificação ou similaridade.

2.4.1 Acurácia

A Acurácia é uma métrica fundamental de avaliação, comumente usada para medir o desempenho geral de modelos de PLN. Representa a proporção de predições corretas em relação ao total de predições. Embora seja uma medida direta, a Acurácia pode ser limitada em cenários desbalanceados, sendo complementada por métricas adicionais, como Precisão, Revocação e F1-Score, para avaliação mais abrangente do desempenho do modelo.

3 REVISÃO BIBLIOGRÁFICA

Até 2 páginas. Trocar título por benchmarking de mercado em caso PIPE. Sugestões: 1) 1 paragrafo falando sobre locais que artigos foram buscados, palavras-chaves utilizadas, quantos artigos foram lidos integralmente ao final. Se foi utilizada a tabela de sumarização, apresentá-la. 2) Colocar cada "grande assunto"em uma subseção. Por exemplo: TCC sobre classificação de doenças cardíacas foi pesquisado métodos de classificação e métodos de IA para auxílio ao diagnóstico de doenças cardíacas. Nesse sentido, teríamos 2 subseções. 3)Fazer uma subseção final chamada Considerações Finais e apresentar lacunas identificadas ou qual a estratégia que o grupo utilizará dado os artigos lidos; 4) em média são lidos de 3-4 artigos por integrante do grupo.

Para realização da revisão bibliográfica foram utilizados as ferramentas de buscas de artigos científicos do *Google Scholar* (https://scholar.google.com/), *IEEE Xplore* (https://ieeexplore.ieee.org/Xplore/home.jsp), *ScienceDirect* (https://www.sciencedirect.com/) e *Semantic Scholar* (https://www.semanticscholar.org/).

Como palavras-chaves na busca foram utilizados termos em inglês, sendo ele, *"semantic similarity between texts"*, *"measure degree of paraphrase"*, *"paraphrase detection"*, *"natural language processing"*, *"measure semantic similarity between answers"* e *"evaluation of descriptve answers"*. Os termos que trouxeram os melhores resultados e estavam presentes nos melhores artigos selecionados foram *"semantic similarity"*, *"natural language processing"* e *"evaluation of descriptve answers"*.

Inicialmente foram selecionados 26 artigos que poderiam ser relevantes para o presente trabalho com base nos temas, uma tabela sumarizada com todos os artigos selecionados pode ser vista na imagem abaixo:

Tipo	Autores	Título	Fonte	Ano	Keywords	URLs
Artigo	Ramachandran L,Gehringer EF	Determining Degree of Relevance of Reviews Using a Graph-Based Text Representation	IEEE	2011	String-based metrics, Paraphrasing, Graph-Based Text Representation,Semantic and syntactic similarities	https://ieeexplore.ieee.org/document/6103362
Artigo	Jiang Y,Hao Y,Zhu X	A Chinese text paraphrase detection method based on dependency tree	IEEE	2016	Word embedding, Bag of words, Dependency relation similarities, Paraphrase detection, Syntactic structures, Lexical features	https://ieeexplore.ieee.org/document/7479003
Artigo	Gustafson N,Pera MS,Ng YK	Nowhere to Hide: Finding Plagiarized Documents Based on Sentence Similarity	IEEE	2008	Copyrighted documents/materials, Paraphrasing information, Sentence-to-sentence similarity, Word-correlation factors, Graphical view of sentences	https://ieeexplore.ieee.org/document/4740531
Artigo	Zhang S,Tan H,Chen L,Lv B	Enhanced Text Matching Based on Semantic Transformation	IEEE	2020	Text matching, semantic transformation, CycleGAN, Transformer network, paraphrase identification, question answer matching	https://ieeexplore.ieee.org/document/8993831
Artigo	Meena K,Lawrance R	Semantic similarity based assessment of descriptive type answers	IEEE	2016	Algorithm, semantic similarity, evaluation, detailed type answers, pruning, stemming, size reduction, vectors, Latent Semantic Analysis (LSA)	https://ieeexplore.ieee.org/document/7725366
Artigo	Kaur A,Sasikumar M	A comparative analysis of various approaches for automated assessment of descriptive an	IEEE	2017	Descriptive answers, Standard descriptive answer, Similarity measures, Graphical representation, Automation of descriptive answer evaluation process	https://ieeexplore.ieee.org/document/8272650
Artigo	Bachman LF,Carr N,Kamei G,Kim	A reliable approach to automatic assessment of short answer free responses	SSL	2002	WebLAS (web-based language assessment system), student responses, natural language processing (NLP) modules, gold standard answer, score assignment	https://api.semanticscholar.org/CorpusID:27889503
Artigo	Thalor MA	A Descriptive Answer Evaluation System Using Cosine Similarity Technique	IEEE	2021	Computer-assisted assessment tools, Descriptive type questions, Machine learning, Cosine similarity technique, Traditional teacher-centric assessment approach	https://ieeexplore.ieee.org/document/9510170
Artigo	Bagaria V,Badve M,Beldar M,Ghu	An Intelligent System for Evaluation of Descriptive Answers	IEEE	2020	Measurement, Semantics,Grammar, Conferences, Task analysis, Pattern matching, Natural language processing	https://ieeexplore.ieee.org/document/9316110
Artigo	Zhang J	Application Research of Similarity Algorithm in the Design of English Intelligent Question A	IEEE	2022	English intelligent question answering system, Sentence similarity, Semantic information, Longest word matching method, Automatic question answering system	https://ieeexplore.ieee.org/document/10031708
Artigo	Poulos M	Near duplicate text detection using graph depiction	IEEE	2016	Kendal Rank Correlation Model, Text Vector Model (TVM), cosine similarity, Jaccard similarity, plagiarism detection	https://ieeexplore.ieee.org/document/7785368
Artigo	Dai Y,Song W,Liu X,Liu L,Zhao X	Recognition of Parallelism Sentence Based on Recurrent Neural Network	IEEE	2018	Parallelism sentence, recurrent neural network, feature extraction, grammar rules, structure, overlap, semantic meaning, test results	https://ieeexplore.ieee.org/document/8663734
Artigo	Wang C,Xu X,Wei Z,Zhang W,Liu Z	LSGC: An Interactive Text Matching Model Combined with Enhanced Encoding	IEEE	2022	Enhanced encoding layer, LSGC model	https://ieeexplore.ieee.org/document/9880792
Artigo	Batanović V,Furlan B,Nikolić B	A software system for determining the semantic similarity of short texts in Serbian	IEEE	2011	Semantic similarity, short texts, Serbian, software system, paraphrase corpus, evaluation results	https://ieeexplore.ieee.org/document/6143778
Artigo	Mahmoud A,Zrigui M	Arabic Semantic Textual Similarity Identification based on Convolutional Gated Recurrent I	IEEE	2021	Paraphrase detection, Natural Language Processing (NLP), semantic textual similarity, Arabic language, deep neural networks, Siamese architecture	https://ieeexplore.ieee.org/document/9548576
Artigo	Jiang Y,Hao Y,Zhu X	A Chinese text paraphrase detection method based on dependency tree	IEEE	2016	Paraphrase detection, dependency tree, bag of words, word embedding, deep neural networks, word similarity, dependency relations, Chinese text corpus	https://ieeexplore.ieee.org/document/7479003
Artigo	Li Q,Shah S,Ghassemi M,Fang R,I	Using paraphrases to improve tweet classification: Comparing WordNet and word embedd	IEEE	2016	Paraphrases, data sparseness issue, high degree of lexical variation, tweet topic classification, WordNet, word embeddings, experiment, outperforms	https://ieeexplore.ieee.org/document/7841094
Artigo	Schlechtweg D,McGillivray B,Hen	SemEval-2020 Task 1: Unsupervised Lexical Semantic Change Detection	SSL	2020	Lexical semantic change detection, clustering, contextualized embeddings, K-Means++, simplicity of the clustering method used	https://api.semanticscholar.org/CorpusID:220686630
Artigo	Cer DM,Diab MT,Agirre E,Lopez-G	SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Ev	SSL	2017	Semantic Textual Similarity (STS), Multilingual and Cross-lingual, Machine Translation (MT), Summarization, Question Answering (QA), Short Answer Grading	https://api.semanticscholar.org/CorpusID:4421747
Artigo	Paul DV,Pawar JD	Use of Syntactic Similarity Based Similarity Matrix for Evaluating Descriptive Answer	IEEE	2014	Descriptive answer, automatic evaluation, similarity matrix, word order similarity, vector-based similarity matrix, syntactic similarity measure, continuous assessment	https://ieeexplore.ieee.org/document/7009583
Artigo	Shaukat MS,Tanzeem M,Ahmad T	Chapter 16 - Semantic similarity–based descriptive answer evaluation	SCD	2021	Semantic similarity;Subjective evaluation;WordNet;Natural language processing	https://www.sciencedirect.com/science/article/pii/B9780128224687000146
Artigo	Sanuvala G,Fatima SS	A Study of Automated Evaluation of Student's Examination Paper using Machine Learning	IEEE	2021	Automated evaluation, student's examination paper, machine learning techniques, written exam, evaluation process, assessment process	https://ieeexplore.ieee.org/document/9397227
Artigo	Kudi P,Manekar A,Daware K,Dhat	Online Examination with short text matching	IEEE	2014	Online Examination System, Objective type questions, Descriptive answers, Automated system, Text mining, Similarity measurement	https://ieeexplore.ieee.org/document/7030847
Artigo	Rowtula V,Oota SR,C.v J	Towards Automated Evaluation of Handwritten Assessments	IEEE	2019	Automated evaluation, handwritten assessments, scaling the education system, evaluation score, handcrafted features, self-supervised	https://ieeexplore.ieee.org/document/8977982
Artigo	Amur ZH,Hooi YK,Soomro GM	Automatic Short Answer Grading (ASAG) using Attention-Based Deep Learning MODEL	IEEE	2022	Short answer grading, automatic short answer grading, ASAG, intellectual and cognitive skills, short sentences, primary and secondary keywords	https://ieeexplore.ieee.org/document/10007187
Artigo	Mohammad Shaharyar Shaukat,	Semantic similarity–based descriptive answer evaluation	SSL	2021	Semantic similarity;subjective evaluation;WordNet;natural language processing	https://api.semanticscholar.org/CorpusID:234234858

Legenda	
	Duplicado
	Selecionado após filtragem

Figura 2 – Figura da tabela de revisão bibliográfica sumarizada.

Após uma filtragem com base nos resumos e palavras-chaves, foram selecionados 4 artigos como base para a revisão bibliográfica como consta na tabela abaixo:

Base	Total encontrados	Após remoção dos Duplicados	Após análise do resumo
IEEE	21	21	2
Science Direct	1	1	1
Semantic Scholar	4	3	1

Tabela 1 – Tabela do funil de leitura.

No final os artigos filtrados foram e lidos integralmente foram:

a) *"Unsupervised Lexical Semantic Change Detection"* (SCHLECHTWEG et al., 2020).

b) *"Use of Syntactic Similarity Based Similarity Matrix for Evaluating Descriptive Answer"* (PAUL; PAWAR, 2014).

c) *"Semantic similarity–based descriptive answer evaluation"* (SHAUKAT et al., 2021).

d) *"A Study of Automated Evaluation of Student's Examination Paper using Machine Learning Techniques"* (SANUVALA; FATIMA, 2021).

Desses artigos pode-se destacar alguns pontos relevantes para o presente trabalho. No caso do artigo*"Use of Syntactic Similarity Based Similarity Matrix for Evaluating Descriptive Answer"*, podemos destacar que o trabalho utiliza a técnica de Análise Semântica Latente (LSA), que é comumente usada para determinar a similaridade de documentos, mas ressalta suas limitações em documentos curtos. O artigo destaca a ausência de abordagens anteriores que se concentrem na avaliação automática de respostas descritivas usando vetores de ordem de palavras.

O método proposto utiliza uma matriz de similaridade entre vetores de ordem de palavras para avaliar respostas descritivas. A similaridade entre os vetores é calculada por meio de uma métrica de similaridade sintática, ou seja baseada na ordem das palavras. Os resultados indicam que a abordagem baseada em ordem de palavras é promissora para a avaliação automática de respostas descritivas. A matriz de similaridade é apresentada como uma ferramenta eficaz para computar as notas de cada pergunta (PAUL; PAWAR, 2014).

No artigo *"Semantic similarity–based descriptive answer evaluation"*, pode-se destacar (SHAUKAT et al., 2021).

No artigo *"A Study of Automated Evaluation of Student's Examination Paper using Machine Learning Techniques"*, pode-se destacar que a pesquisa faz uso de Processamento de Linguagem Natural (NLP) para automatizar o processo de avaliação,especialmente a similaridade de cosseno e índices de similaridade, são empregadas para atribuir notas às respostas (SANUVALA; FATIMA, 2021).

No artigo *"A Study of Automated Evaluation of Student's Examination Paper using Machine Learning Techniques"*, o artigo propõe o uso de embeddings de tipo (type embeddings) e embeddings contextualizados (token embeddings) para representar as palavras. Primeiro, é introduzida a distribuição de frequência de sentido (SFD), e a detecção de mudança binária é definida em termos de limiares de frequência. Após isso, a distância de Jensen-Shannon (JSD) entre as distribuições normalizadas de frequência é utilizada para medir a mudança graduada(SANUVALA; FATIMA, 2021).

4 METODOLOGIA

Até 3 páginas. Rever slides sobre estruturação da metodologia, retomar objetivo do trabalho e colocar qual métodologia escolhida de acordo com objetivos e métodos.

4.1 ABORDAGEM DE PESQUISA:

Levando em conta que o presente trabalho possui como objetivo realizar avaliação automática de respostas dissertativas, pretende-se que o resultado final do mesmo seja uma proposta de resolução desse problema. Assim, podemos classificar sua abordagem de metodologia como experimental, haja vista que serão realizados experimentos com os dados e as técnicas, que serão descritas no decorrer do texto, afim de atingir o objetivo proposto.

4.2 BASES DE DADOS:

Como fonte principal de dados, utilizaremos o *DataSet ASQA (Answer Summaries for Questions which are Ambiguous)* da *Google Research* em parceria com as universidade de *Duke University* e *Cornell University*, o *DataSet* contém respostas dissertativas para questões com perguntas ambíguas, isso permitirá a construção dos experimentos e refino das técnicas que serão utilizadas no presente trabalho (STELMAKH et al., 2022).

Além da fonte principal de dados, também serão utilizados dados fornecidos pela Professora Leila Bergamasco. Os dados possuem as respostas dissertativas dos alunos de Ciência da Computação do Centro Universitário FEI para questões do ENADE, sendo limitados as turmas do 5° ao 8° ciclo do curso.

Ademais, existe a possibilidade de que um futuro questionário seja confeccionado para que, com a ajuda voluntária dos alunos da mesma instituição, mais dados sejam coletados e usados no presente trabalho. Essa possibilidade está aberta, mas só será realizada caso seja efetivamente necessário.

4.3 MATERIAIS:

Serão utilizados computadores para o desenvolvimento da experimentação e a documentação do processo. Os computadores principais utilizados serão de posse própria, caso seja necessário, também podem ser utilizados computadores disponibilizados no campus do Centro Universitário FEI.

Se no decorrer do processo de experimentação, dificuldades em relação as capacidades de processamento e memórias dos computadores forem identificados, abre-se também a possibilidade do uso de plataformas disponibilizadas *online*, como o *Google Colab* (https://colab.google/) e a *Weights & Biases* (https://wandb.ai/site/), ambas oferecem possibilidade de uso gratuito para estudantes que utilizarem apenas com fins acadêmicos.

4.4 MÉTODOS:

Serão utilizados métodos de NLP, tais como mineração de texto, medição de distância de cossenos (para mensurar similaridade de textos), frequência de termos similares (SFD), presença de palavras-chaves (KW), ordem de sequência das palavras, entre outros. Para compor toda a metodologia, pretende-se elaborar uma métrica de avaliação do grau de similaridade semântica entre dois conteúdos. Assumindo que dois textos aleatórios sejam cópias idênticas, sua similaridade poderia ser descrita em uma escala percentual, como 100%.

Por outro lado haverão textos que possuirão conteúdo sintaticamente diferentes, sendo assim, é esperado que sua similaridade diminua, porém, ainda contendo um grau relevante de similaridade semântica entre uma respostas fornecida por um aluno, que esteja classificada como correta, e uma resposta modelo esperada pelo professor.

Desta forma a hipótese é que, para avaliarmos tal similaridade, será necessário avaliar uma série de fatores importantes que irão compor a métrica de avaliação proposta. Esses fatores seriam:

a) **As métricas da sintaxe do texto:** Tal fator será levado em consideração tendo em vista que os trabalhos avaliados na revisão bibliográfica demonstraram a importância da ordem em que as sequências de palavras estão posicionadas no texto.

b) **A frequência de palavras similares (SFD):** Pois também foi demonstrado nos trabalhos avaliados na revisão bibliográfica que essa medida estatística é relevante para a avaliação das respostas.

c) **A medição da distância de cossenos:** Essa medida tem relevância para a métrica pois mensura a similaridade semântica entre dois textos através de suas representações vetoriais.

d) **A presença de palavras-chave (*keywords*):** Serão palavras definidas para cada questão pelo seu confeccionador como termos com um grau mais elevado de relevância para a resposta esperada do aluno. determinadas como parte da resposta padrão para aquela questão.

Todos os fatores apresentados acima já foram utilizados de maneira isolada por diferentes trabalhos como uma forma de avaliação. No caso do presente trabalho pretende-se realizar uma junção dos fatores em uma métrica única para avaliação, averiguando-se ao longo do desenvolvimento do trabalho qual a relevância de cada um deles, para que um peso ajustado seja atribuído para cada fator da métrica.

Caso a métrica proposta acima apresente bons resultados, pode-se cogitar a elaboração de uma segunda métrica, em que dois outros fatores seriam adicionados como uma possível melhoria à primeira, sendo eles:

a) Verificar se um texto pode ser classificado como paráfrase de outro, já que o trabalho possui como hipótese que toda resposta correta é em algum grau uma paráfrase da resposta modelo. Com a identificação da paráfrase, como pode ser feita a medição do grau de parafraseamento entre os dois textos.

b) A quantidade de modificação necessário para que a resposta fornecida seja transformada lexicalmente e sintaticamente na resposta modelo. Isso seria chamado de grau de modificação.

Esses dois fatores não foram considerados nos trabalhos revisados anteriormente, na eventual proposta de uma segunda métrica, ter-se-á como hipótese que os dois fatores resultarão em uma melhoria no resultado.

4.5 AVALIAÇÃO:

Para avaliação do desempenho das técnicas propostas, as bases de dados serão dividas em duas, uma primeiramente para treinamento e refino dos experimentos. Após os resultados estarem satisfatórios, a segunda parte dos dados será utilizada para a validação dos resultados obtidos pelo algoritmo, verificando se estão condizente com os resultados fornecidos pelas avaliações registradas nos dados e se seu funcionamento é geral ou se há algum viés nos resultados.

5 PROPOSTA EXPERIMENTAL

Até 2 páginas. Rever slides sobre proposta experimental. Colocar estratégia de testes por exemplo, esse capítulo é bem específico no que será executado e implementado. MANDATÓRIO adicionar uma subseção com cronograma e para projetos do tipo PIPE uma subseção de até 1 página com análise de viabilidade econômica e técnica.

Como proposta para experimentação do presente trabalho, será realizado a avalição das questões dissertativas atarvés de um algoritmo automático que leva em consideração a métrica de pontuação proposta nos capitulos anteriores do texto, tanto com seus fatores em conjunto, quanto com eles individualmente, o resultado das avaliações realizadas pelo algoritmo será comparado aos valores de avaliação dos professores que estão presentes nas bases de dados específicadas anteriormente no capítulo de metodologia.

A proposta experimental pode ser dividida nos seguintes tópicos:

a) Avaliação individual da presença de palavras chaves: O algoritmo proposto deve avaliar se as palavras chaves determinadas para aquela questão, estão presentes no texto e pontuar com base na quantidade de palavras chaves presentes no texto. Essa avalição por si só muito provavelmente não será precisa.

b) Avalição individual da frequência de palavras (SFD): O algoritmo realizará a medição da frequência das palavras no texto da resposta padrão e da resposta fornecida pelo aluno, cada palavra terá sua frequência em ambos os textos e a diferença entre as duas será medida em porcentagem. Caso palavras diferentes apareçam no texto da respota do aluno, podemos levar em consideração inicialmente a possibilidade de descarata-las, outras possibilidades futuras também podem ser consideradas caso melhores abordagens sejam encontradas na literatura científica.

c) Avalição individual da sintaxe do texto: Utilizando vetores de ordem de palavras o algoritmo deve realizar a medição das métricas de sintaxe do texto, primeiramente da resposta padrão, em sequência, das respotas dos alunos. O vetor de ordem de palavras da respota padrão será comparado com os vetores de ordem de palavras que representem as respostas dos alunos.

d) Avaliçao semantica através da distância de cossenos: Na avaliação da distância de cossenos os textos serão representados em vetores de palavras que representam a similaridade direcional, não a ordem como no item anterior, conforme o ângulos

calculado entre os vetores diminui, sabemos que o grau de similaridade entre os textos é aumenta.

Além das avaliações individuais definidas acima, as métrica individuais serão combinas em duplas e em trios para que os resultado obtidos através dessas combinções sejam comparados com a junção de todas 4 métricas, tendo como hipotese que as 4 métricas em conjunto funcionarão melhor do que individualmente, em duplas ou trios.

Em todas as métricas combinadas, os diferentes fatores devem possuir pesos que representem o quão relevante cada elemento é para uma avalição da respota. Com base nas avaliações individuais realizadas inicialmente, será obtido quais dos fatores possuem uma proximidade maior com os valores das avalições dos professores disponíveis nas bases de dados, podemos inicialmente que quanto maior a proximidade dos valores individuais obtidos com as avaliações nas bases de dados, mais relevantes esse fator deve ser em seu peso. Com o objetivo de obter a melhor precisão possível, os pesos inicias serão modificados para mais ou menos relevância, afim de que o resultado final obtido seja o mais próximo possível dos resultados das avaliações feitas pelos professores disponíveis nas bases de dados.

6 CONCLUSÃO

Até 1 página

REFERÊNCIAS

AMUR, Zaira Hassan; HOOI, Yew Kwang; SOOMRO, Gul Muhammad. Automatic Short Answer Grading (ASAG) using Attention-Based Deep Learning MODEL, p. 1–7, 2022. DOI: 10.1109/ICDI57181.2022.10007187. Disponível em: https://ieeexplore.ieee.org/document/10007187.

BACHMAN, Lyle F et al. A reliable approach to automatic assessment of short answer free responses, 2002. Disponível em: https://aclanthology.org/C02-2023.pdf.

BACHMAN, Lyle F. et al. A Reliable Approach to Automatic Assessment of Short Answer Free Responses. In: INTERNATIONAL Conference on Computational Linguistics. [S.l.: s.n.], 2002. Disponível em: https://api.semanticscholar.org/CorpusID:27889503.

BAGARIA, Vinal et al. An Intelligent System for Evaluation of Descriptive Answers, p. 19–24, 2020. DOI: 10.1109/ICISS49785.2020.9316110. Disponível em: https://ieeexplore.ieee.org/document/9316110.

BATANOVIĆ, Vuk; FURLAN, Bojan; NIKOLIĆ, Boško. A software system for determining the semantic similarity of short texts in Serbian, p. 1249–1252, 2011. DOI: 10.1109/TELFOR.2011.6143778. Disponível em: https://ieeexplore.ieee.org/document/6143778.

CER, Daniel Matthew et al. SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Evaluation, 2017. Disponível em: https://api.semanticscholar.org/CorpusID:4421747.

DAI, Yange et al. Recognition of Parallelism Sentence Based on Recurrent Neural Network, p. 148–151, 2018. DOI: 10.1109/ICSESS.2018.8663734. Disponível em: https://ieeexplore.ieee.org/document/8663734.

GUSTAFSON, Nathaniel; PERA, Maria Soledad; NG, Yiu-Kai. Nowhere to Hide: Finding Plagiarized Documents Based on Sentence Similarity. v. 1, p. 690–696, 2008. DOI: 10.1109/WIIAT.2008.16. Disponível em: https://ieeexplore.ieee.org/document/4740531.

JIANG, Yipeng; HAO, Yu; ZHU, Xiaoyan. A Chinese text paraphrase detection method based on dependency tree, p. 1–5, 2016. DOI: 10.1109/ICNSC.2016.7479003. Disponível em: https://ieeexplore.ieee.org/document/7479003.

KAUR, Amarjeet; SASIKUMAR, M. A comparative analysis of various approaches for automated assessment of descriptive answers. In: 2017 International Conference on Computational Intelligence in Data Science(ICCIDS). [S.l.: s.n.], 2017. P. 1–7. DOI: 10.1109/ICCIDS.2017.8272650. Disponível em: https://ieeexplore.ieee.org/document/8272650.

KUDI, Pooja et al. Online Examination with short text matching, p. 56–60, 2014. DOI: 10.1109/GCWCN.2014.7030847. Disponível em: https://ieeexplore.ieee.org/document/7030847.

LI, Quanzhi et al. Using paraphrases to improve tweet classification: Comparing WordNet and word embedding approaches, p. 4014–4016, 2016. DOI: 10.1109/BigData.2016.7841094. Disponível em: https://ieeexplore.ieee.org/document/7841094.

MAHMOUD, Adnen; ZRIGUI, Mounir. Arabic Semantic Textual Similarity Identification based on Convolutional Gated Recurrent Units, p. 1–7, 2021. DOI: 10.1109/INISTA52262.2021.9548576. Disponível em: https://ieeexplore.ieee.org/document/9548576.

MARSLAND, Stephen. **Machine Learning: An Algorithmic Perspective, Second Edition**. 2nd. [S.l.]: Chapman & Hall/CRC, 2014. ISBN 1466583282.

MEENA, K; LAWRANCE, R. Semantic similarity based assessment of descriptive type answers. In: 2016 International Conference on Computing Technologies and Intelligent Data Engineering (ICCTIDE'16). [S.l.: s.n.], 2016. P. 1–7. DOI: 10.1109/ICCTIDE.2016.7725366. Disponível em: https://ieeexplore.ieee.org/document/7725366.

OLIVEIRA, Katya Luciane de; SANTOS, Acácia Aparecida Angeli dos Santos. Avaliação da aprendizagem na universidade. pt. **Psicologia Escolar e Educacional**, scielopepsic, v. 9, p. 37–46, jun. 2005. ISSN 1413-8557. Disponível em: http://pepsic.bvsalud.org/scielo.php?script=sci_arttext&pid=S1413-85572005000100004&nrm=iso.

PAUL, Dimple V.; PAWAR, Jyoti D. Use of Syntactic Similarity Based Similarity Matrix for Evaluating Descriptive Answer, p. 253–256, 2014. DOI: 10.1109/T4E.2014.60. Disponível em: https://ieeexplore.ieee.org/document/7009583.

POULOS, Marios. Near duplicate text detection using graph depiction, p. 1–6, 2016. DOI: 10.1109/IISA.2016.7785368. Disponível em: https://ieeexplore.ieee.org/document/7785368.

RAMACHANDRAN, Lakshmi; GEHRINGER, Edward F. Determining Degree of Relevance of Reviews Using a Graph-Based Text Representation, p. 442–445, 2011. DOI: 10.1109/ICTAI.2011.72. Disponível em: https://ieeexplore.ieee.org/document/6103362.

ROWTULA, Vijay; OOTA, Subba Reddy; C.V, Jawahar. Towards Automated Evaluation of Handwritten Assessments, p. 426–433, 2019. DOI: 10.1109/ICDAR.2019.00075. Disponível em: https://ieeexplore.ieee.org/document/8977982.

SANUVALA, Ganga; FATIMA, Syeda Sameen. A Study of Automated Evaluation of Student's Examination Paper using Machine Learning Techniques, p. 1049–1054, 2021. DOI: 10.1109/ICCCIS51004.2021.9397227.

SCHLECHTWEG, Dominik et al. SemEval-2020 Task 1: Unsupervised Lexical Semantic Change Detection. **ArXiv**, abs/2007.11464, 2020. Disponível em: https://api.semanticscholar.org/CorpusID:220686630.

SHAUKAT, Mohammad Shaharyar et al. Chapter 16 - Semantic similarity–based descriptive answer evaluation. Edição: Sarika Jain, Vishal Jain e Valentina Emilia Balas. Academic Press,

p. 221–231, 2021. DOI: https://doi.org/10.1016/B978-0-12-822468-7.00014-6. Disponível em: https://www.sciencedirect.com/science/article/pii/B9780128224687000146.

STELMAKH, Ivan et al. Asqa: Factoid questions meet long-form answers. **arXiv preprint arXiv:2204.06092**, 2022. Disponível em: https://aclanthology.org/2022.emnlp-main.566.pdf.

THALOR, Meenakshi A. A Descriptive Answer Evaluation System Using Cosine Similarity Technique. In: 2021 International Conference on Communication information and Computing Technology (ICCICT). [S.l.: s.n.], 2021. P. 1–4. DOI: 10.1109/ICCICT50803.2021.9510170. Disponível em: https://ieeexplore.ieee.org/document/9510170.

WANG, Chenglin et al. LSGC: An Interactive Text Matching Model Combined with Enhanced Encoding, p. 1–7, 2022. DOI: 10.1109/IJCNN55064.2022.9889792. Disponível em: https://ieeexplore.ieee.org/document/9889792.

ZHANG, Jing. Application Research of Similarity Algorithm in the Design of English Intelligent Question Answering System. In: 2022 IEEE 2nd International Conference on Mobile Networks and Wireless Communications (ICMNWC). [S.l.: s.n.], 2022. P. 1–4. DOI: 10.1109/ICMNWC56175.2022.10031708.

ZHANG, Shutao et al. Enhanced Text Matching Based on Semantic Transformation. **IEEE Access**, v. 8, p. 30897–30904, 2020. DOI: 10.1109/ACCESS.2020.2973206. Disponível em: https://ieeexplore.ieee.org/document/8993831.